

The background of the slide is a photograph of the Moscow State University main building, a massive Stalinist skyscraper with a central spire, set against a blue sky with light clouds. The building is seen from a distance, with some trees and other city buildings in the foreground.

# **Глубокое обучение**

## **Обучение без учителя**


**Дьяконов А.Г.**

**Московский государственный университет  
имени М.В. Ломоносова (Москва, Россия)**


Обучение без учителя Unsupervised Learning			
Невероятностные модели	Вероятностные (генеративные) модели		
<ul style="list-style-type: none"> <li>• Sparse Coding +</li> <li>• Autoencoders</li> <li>• k-means, ...</li> </ul>	Плотность в явном виде (explicit density)		Плотность в неявном виде (implicit density)
	Tractable Models	Non-Tractable Models	<ul style="list-style-type: none"> <li>• GAN</li> <li>• Momet Matching Networks</li> </ul>
	<ul style="list-style-type: none"> <li>• Fully observed Belief Nets</li> <li>• NADE</li> <li>• PixelRNN</li> </ul>	<ul style="list-style-type: none"> <li>• Boltzmann Machines ~</li> <li>• VAE</li> <li>• Helmholtz Machines</li> </ul>	

## Автокодировщики (Auto-encoders)

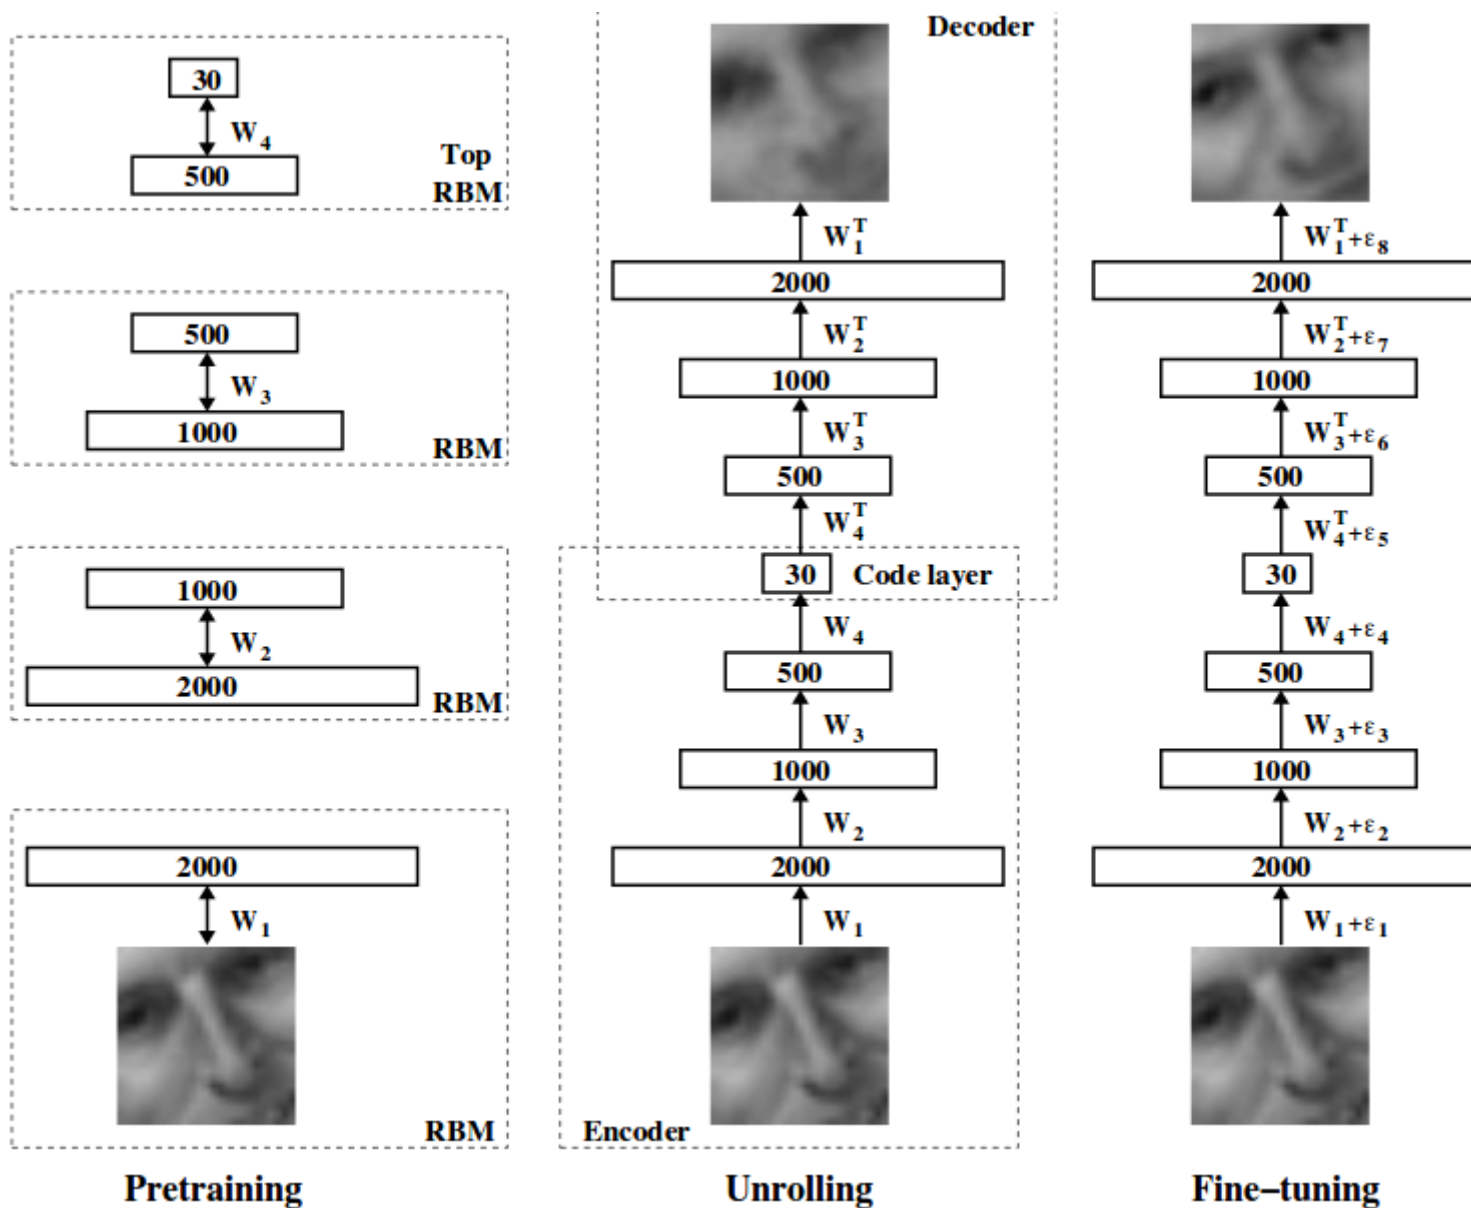
### ► Fully Contented Auto-encoder



### ► Convolution Auto-encoder



# Глубокие автокодировщики



## **Зачем нужны автокодировщики**

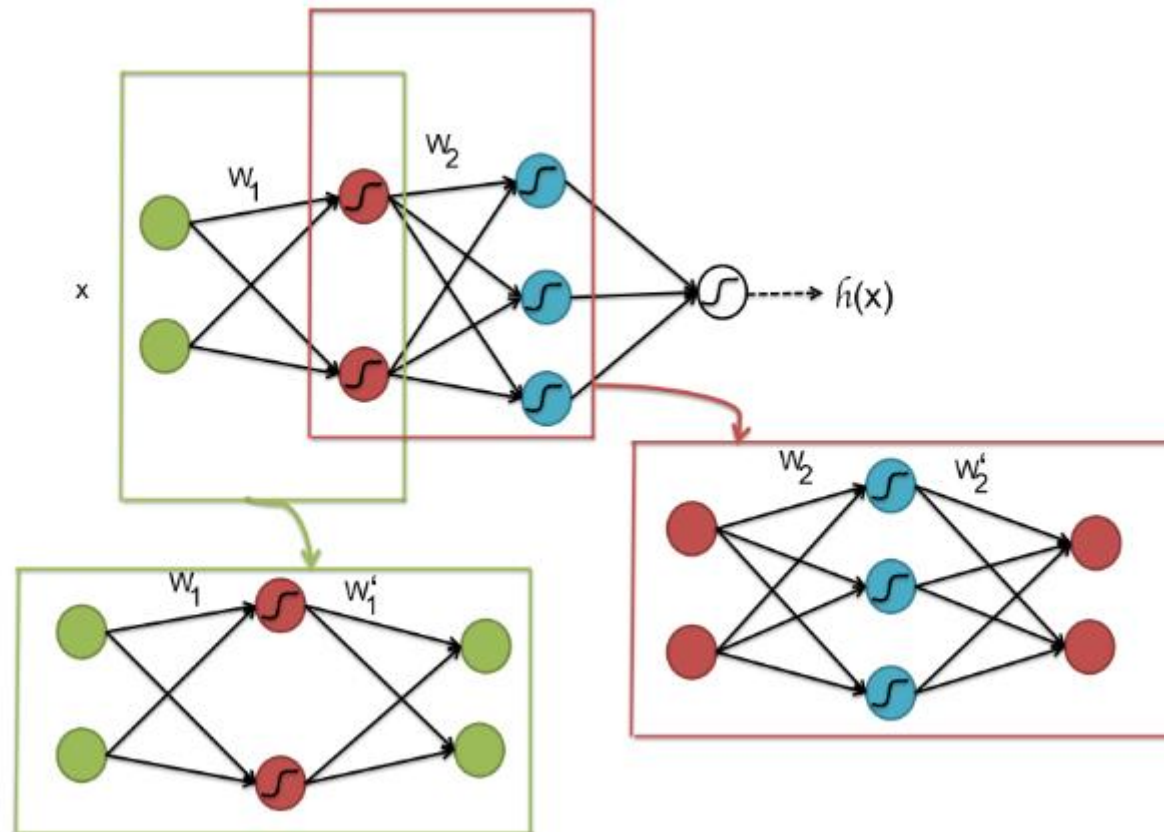
- **сокращение размерности**
- **выделение признаков (для других алгоритмов)**
- **предобучение**
- **специальные задачи (ниже: устранение шума)**

### **Denoising Autoencoder**

**увеличение выборки с помощью  
дополнения к ней зашумлённых изображений  
зашумления разного типа**

- **больше данных**
- **правильнее формируемые признаки**

## Предобучение с помощью автокодировщика последовательно обучать автокодировщики



**первый слой должен воспроизводить вход  
второй слой должен воспроизводить первый и т.д.  
обучить последний слой, используя размеченные данные  
обучить всю сеть, используя размеченные данные**

<https://cs.stanford.edu/~quocle/tutorial2.pdf>



## Sparse Coding

**Постановка задачи. Выборка  $\{x_i\}_{i=1}^m$ , базисы  $\{b_i\}_{i=1}^k$ , хотим представить в виде разреженной линейной комбинации (sparse linear combination)**

$$x_i \approx \sum_{j=1}^k \alpha_{ij} b_j :$$


**в основном все  $\alpha_{ij}$  нулевые!**

$$\sum_{i=1}^m \left\| x_i - \sum_{j=1}^k \alpha_{ij} b_j \right\|_2^2 + \lambda \sum_{i=1}^m \sum_{j=1}^k |\alpha_{ij}| \rightarrow \min_{\alpha, b}$$


**Alternative optimization – попеременно фиксировать базис и коэффициенты**

## Sparse Coding


Natural Images



Learned bases: "Edges"



New example



$= 0.8 *$



$+ 0.3 *$



$+ 0.5 *$



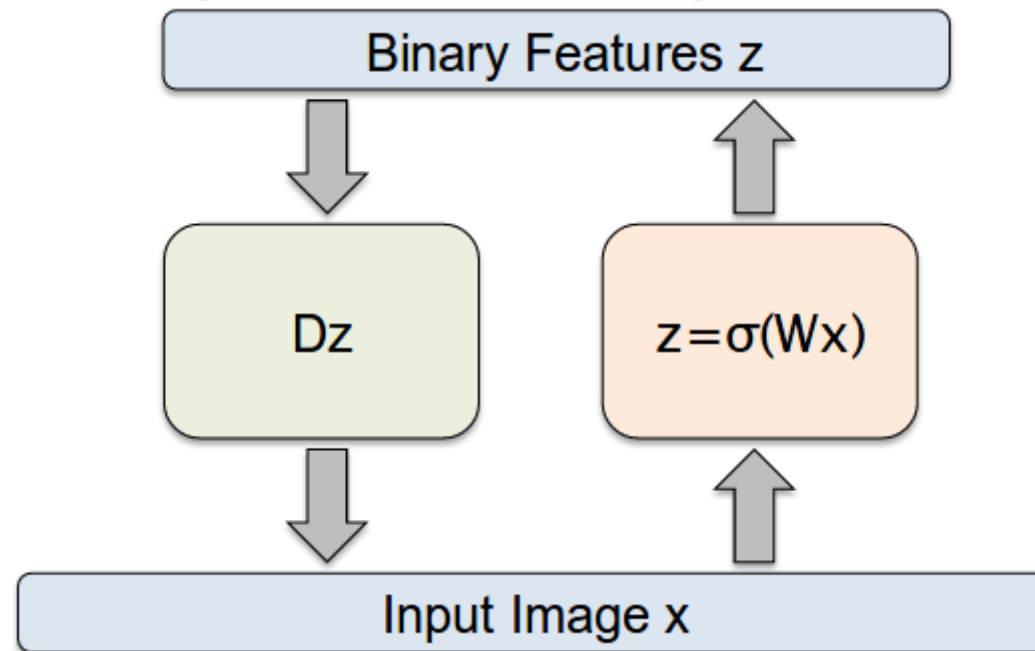
$$x = 0.8 * \phi_{36} + 0.3 * \phi_{42} + 0.5 * \phi_{65}$$



## Sparse Coding

**вписывается в парадигму автокодировщика!**

**Kavukcuoglu, Ranzato, Fergus, LeCun, 2009**



**к скрытых бинарных нейронов**

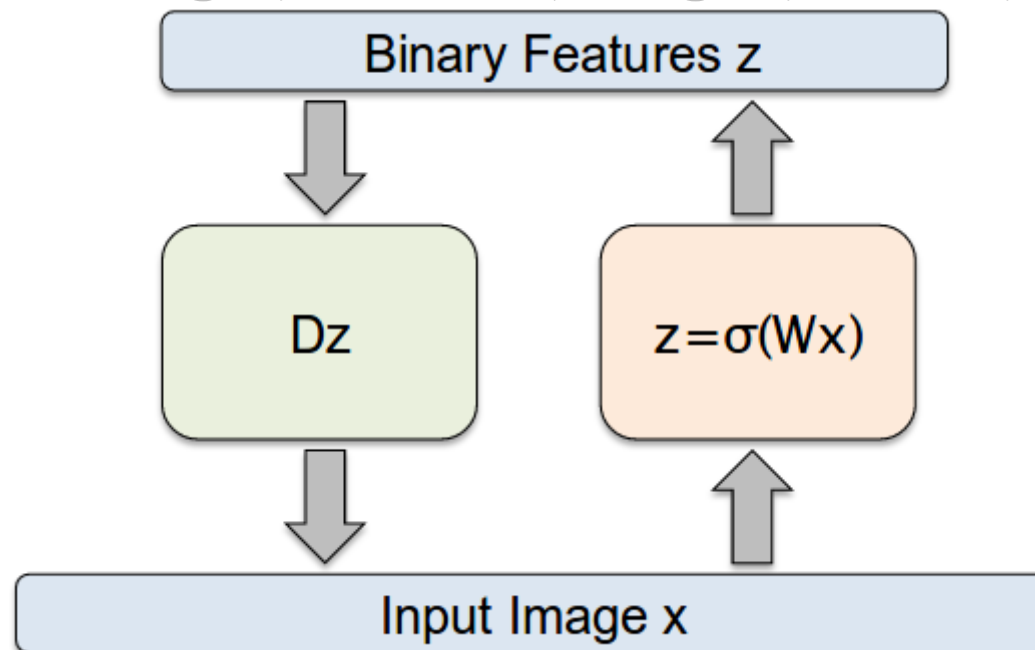
$$X_j \approx \sum_{t=1}^k D_{jt} \sigma \left( \sum_{i=1}^n W_{ti} X_i \right)$$

**+ L1 регуляризация на значения  $z = \sigma(Wx)$**

## Sparse Coding

**вписывается в парадигму автокодировщика!**

**Kavukcuoglu, Ranzato, Fergus, LeCun, 2009**



**к скрытых бинарных нейронов**


$$\| Dz - x \|_2^2 + \lambda \| z \|_1 + \| \sigma(Wx) - z \|_2^2 \rightarrow \min_{D, W, z}$$

## Использование RBM

4 million **unlabelled** images



Learned features (out of 10,000)



REUTERS  
AP Associated Press

Reuters dataset:  
804,414 **unlabeled**  
newswire stories  
Bag-of-Words



Learned features: ``topics''

russian  
russia  
moscow  
yeltsin  
soviet

clinton  
house  
president  
bill  
congress

computer  
system  
product  
software  
develop


trade  
country  
import  
world  
economy

stock  
wall  
street  
point  
dow

## Использование RBM

$$P_{\theta}(v, h) = \frac{1}{Z(\theta)} \exp \left( \sum_{ij} W_{ij} v_i h_j + \sum_i b_i v_i + \sum_j a_j h_j \right)$$

## Глубокие RBM (Deep Boltzmann Machines)




**Многоуровневое пространство  
скрытых переменных  
(разные степени детализации)**

Salakhutdinov, Hinton, 2009

## **SOM – Самоорганизующиеся карты Кохонена**

**Хотим отобразить пространство в регулярную структуру  
(например, узлы решётки решётки)**

**Решётка задаёт соседство узлов  
(топологию)**





## Самоорганизующиеся карты Кохонена

### Алгоритм обучения

**1. Подаём объект  $x$**

**2. Находим самый близкий узел**

$$(a, b) = \arg \max_{(i, j)} \text{sim}(x, w_{ij})$$

**соревнование ~ нейрон-победитель, пример**  $\text{sim}(x, w_{ij}) = - \| x - w_{ij} \|$

**3. Коррекция весов**

$$w_{ij} \leftarrow w_{ij} + \eta K((a, b), (i, j)) x$$

**веса нейронов около победителя корректируются больше...**

**~ кооперация, пример**  $K((a, b), (i, j)) = \exp(-|a - i| + |b - j|)$

$$(a, b) = \arg \max_{(i, j)} \text{sim}(x, w_{ij})$$


## Регуляризация в автокодировщиках

- + шум (в Denoising Autoencoders)
- + специальное слагаемое к функции ошибки (в Sparse Autoencoders)
- + специальное слагаемое к функции ошибки для стабильности латентного представления (используем Якобиан в Contractive Autoencoders)

## Adversarial Autoencoders (AAE)

**Цель: наделить структурой пространство скрытых переменных**

**+ adversarial loss для соответствия распределения ПСП произвольному априорному**



## Отличие ААЕ от VAE

$$\mathcal{L} = \underbrace{\mathbb{E}_x \left[ \mathbb{E}_{q(z|x)} [-\log p(x|z)] \right]}_{\text{Reconstruction Error}} + \underbrace{\mathbb{E}_x [\text{KL}(q(z|x) || p(z))]}_{\text{KL Regularizer}}$$

↓  
Replaced by adversarial loss in AAE

**в VAE мы обратное распространение через KL  $\Rightarrow$  должна быть аналитическая запись  $p(z)$**







**в ААЕ достаточно сэмплировать из априорного распределения**

**ниже (см. рис.) разные априорные распределения: нормальное в 2D и смесь нормальных**

Alireza Makhzani, Jonathon Shlens, Navdeep Jaitly, Ian Goodfellow, Brendan Frey «Adversarial Autoencoders» // <https://arxiv.org/abs/1511.05644>

Adversarial Autoencoder

Variational Autoencoder

Manifold of  
Adversarial Autoencoder

## Wasserstein Auto-Encoders (доклад на ICLR 2018) – обобщение AAE

$$D_{\text{WAE}}(P_X, P_G) := \inf_{Q(Z|X) \in \mathcal{Q}} \underbrace{\mathbb{E}_{P_X} \mathbb{E}_{Q(Z|X)} [c(X, G(Z))]}_{\text{Reconstruction cost}} + \underbrace{\lambda \cdot \mathcal{D}_Z(Q_Z, P_Z)}_{\text{Regularizer encourages the encoded distribution to match the prior}}$$

**VAE&GAN – минимизируют меру различия распределения данных и модели**

**WAE – «регуляризованное» расстояние Вассерштейна между модельным и целевым распределением**

**WAE = AAE при  $c(x, y) = \|x - y\|_2^2$**

**WAE использует не обязательно состязательную (adversarial) меру  $D_Z$**



## Расстояние Вассерштейна-1

$$W(p, p') = \inf_{(x, y) \sim \Pi(p, p')} \|x - y\|$$

где  $\Pi(p, p')$  – множество всех совместных распределений с соответствующими проекциями  
Arjovsky et al 2017

**Эквивалентно:**

$$W(p, p') = \sup_{\|f\|_L \leq 1} \mathbb{E}_{x \sim p} f(x) - \mathbb{E}_{x \sim p'} f(x)$$

**Sup по липшицевым функциям с константой Липшица  $\leq 1$**

**На практике  $f$  аппроксимируется с помощью НС, где все веса клиппируются, чтобы лежать на компактном пространстве (например на гиперкубе со стороной  $\varepsilon$ )**